



Clustering des utilisateurs
d'une néo-banque en
fonction de leur
utilisation des produits

Karen MBELEL



Sommaire

1. OBJECTIFS

2. PRÉSENTATION DES DONNÉES

3. ANALYSE EXPLORATOIRE DES DONNÉES

4. PRÉ-TRAITEMENT DES DONNÉES

5. SEGMENTATION DES CLIENTS (CLUSTERING)

6. SUGGESTIONS D'AMÉLIORATION



Objectifs du projet

- Étudier la répartition des transactions selon différents critères.
- Appliquer des méthodes de segmentation client.
- Proposer des recommandations stratégiques aux néo-banques.



Présentation des données

	user_id	transaction_id	amount_usd	transactions_currency	transactions_type	direction	transactions_state	ea_cardholderpresence
781974	user_2630	transaction_781974	4.510000	GBP	CARD_PAYMENT	OUTBOUND	COMPLETED	FALSE
937737	user_4254	transaction_937737	0.430000	EUR	TRANSFER	OUTBOUND	COMPLETED	nan
907828	user_9801	transaction_907828	39.160000	GBP	CARD_PAYMENT	OUTBOUND	COMPLETED	FALSE
784628	user_8735	transaction_784628	13.910000	EUR	TRANSFER	OUTBOUND	COMPLETED	nan
662460	user_9590	transaction_662460	4.760000	EUR	CARD_PAYMENT	OUTBOUND	COMPLETED	FALSE
280139	user_6670	transaction_280139	27.800000	GBP	CARD_PAYMENT	OUTBOUND	COMPLETED	FALSE
355572	user_5250	transaction_355572	0.000000	PLN	CARD_PAYMENT	OUTBOUND	DECLINED	FALSE
749979	user_1402	transaction_749979	5.510000	CZK	CARD_PAYMENT	OUTBOUND	COMPLETED	FALSE
374753	user_4568	transaction_374753	0.380000	PLN	CARD_PAYMENT	OUTBOUND	COMPLETED	FALSE
17327	user_5718	transaction_17327	0.230000	AED	EXCHANGE	OUTBOUND	COMPLETED	nan

Présentation des données

ea_merchant_mcc	merchant_category	ea_merchant_city	ea_merchant_country	created_date
5411.000000	Retail outlet services	Sant Antoni D	ESP	2018-07-12 18:33:47.773384
nan	Unknown	nan	nan	2019-03-08 02:13:47.499594
7230.000000	Miscellaneous stores	Bradenton Bea	USA	2018-10-30 05:33:05.329676
nan	Unknown	nan	nan	2018-11-17 14:34:00.361416
4112.000000	Transportation services	Victoria V 3	GBR	2018-08-08 10:02:20.173828
5812.000000	Miscellaneous stores	M'ster M1 4	GBR	2019-01-20 21:33:10.600264
5999.000000	Miscellaneous stores	San Francisco	GBR	2019-01-19 04:27:44.721800
5331.000000	Retail outlet services	Praha 5	CZE	2019-01-30 09:51:48.941568
7994.000000	Business services	Fb.me/cc	IRL	2019-04-06 08:27:07.893760
nan	Unknown	nan	nan	2019-04-16 04:10:21.204878


- **ea_merchant_mcc** : code marchand (catégorie)
- **merchant_category** : catégorie de marchands
- **direction** : sens de la transaction (entrant/sortant)
- **ea_cardholderpresence** : indique s'il s'agit d'un paiement physique




Analyse exploratoire des données



Répartition des transactions par montant et catégorie




Répartition des transactions par Type et Direction




Montant total des transactions par devise

Montant Total des Transactions (USD) par Devise



- les devises (EUR, CHF, GBP, CZK) ont les montants les plus élevés .
- la couronne tchèque (CZK) se démarque parmi les autres devises.

Analyse de la présence du titulaire (e_cardholderpresence)





Pré-traitement des données



Gestion des valeurs manquantes

- méthode `fillna()`
- méthode `dropna()`

```
df["ea_cardholderpresence"].fillna("unknown", inplace=True)
df["direction"].fillna("OUTBOUND", inplace=True)
df.dropna(subset=["user_id"], inplace=True)
df.dropna(subset=["created_date"], inplace=True)
df["ea_merchant_mcc"].fillna(9999, inplace=True)
df["ea_merchant_city"].fillna("unknown_city", inplace=True)
df["ea_merchant_country"].fillna("unknown_country", inplace=True)
```



Création des features

- Average_transaction_amount
- Total_transactions
- Inbound_ratio
- Inbound_transactions
- Outbound_transactions
- Category_ratio
- top_merchant_category
- top_merchant_currency
- top_merchant_country



Etapes

- **Suppression du user_id**

```
# Supprimer user_id  
df_user = df_user.drop(columns=["user_id"])
```

- **One-hot encoding**

```
# One-hot encoding  
df_user = pd.get_dummies(df_user, columns=["top_merchant_category", "top_merchant_country"])
```

- **Normalisation des variables**

```
from sklearn.preprocessing import MinMaxScaler  
import pandas as pd  
  
# Exemple pour scaler df_user et créer un DataFrame  
scaler = MinMaxScaler()  
df_user_scaled = pd.DataFrame(scaler.fit_transform(df_user), columns=df_user.columns)
```






Segmentation des clients



Nombre de clusters

- **Méthode du coude (elbow method)**




- Nombre de cluster optimal = 3


```
.. cluster
2      3895
0      3748
1      1964
```


Visualisation des clusters

- **Méthode PCA (Principal Component Analysis)**



Résultats du clustering



- **Cluster 0:** gamme moyenne
- **Cluster 1:** bonne répartition entre fort et moyen potentiel
- **Cluster 2:** majorité de clients à fort potentiel

Suggestions d'améliorations

- **Optimisation des features** : tester d'autres variables.
- **Affinage du nombre de clusters** : silhouette score, DBSCAN.
- **Segmentation dynamique** : clustering temporel, hiérarchique.





Recommendations & Conclusion



Recommandations

1) Personnalisation des offres

- Adapter les services et promotions.
- Proposer des avantages spécifiques aux clients à fort potentiel
- Encourager les utilisateurs à faible engagement

2) Optimisation de l'expérience utilisateur

- Améliorer la transparence et la catégorisation des transactions
- Analyser les raisons des refus de transactions en présentiel et proposer des solutions



Conclusion

- Différences marquées dans les habitudes de transaction.
- Opportunités d'optimisation.
- Encourager les utilisateurs à faible engagement.
- Amélioration de l'engagement et du modèle économique.
- Perspectives d'enrichissement.





Merci

